

US Accidents Severity 예측 프로젝트

교통사고 발생 조건 기반 다중분류 모델
및 Streamlit 웹앱 구현

Team 4 Machine Learning Project · 2026

교통시스템공학과 예상형


교통시스템공학과 강우석

전자공학과 윤석민

생명과학과 정시영



발표 구성



사고 발생 시점에서 알 수 있는 정보를 바탕으로 **Severity**를 예측하고, 최종 모델을 웹앱으로 연결

문제 정의: 사고 조건 → Severity 등급 예측



- 교통사고 심각도는 사고 대응 우선순위와 교통관리 정책에 활용 가능
- **Severity** : 사고로 인한 교통 지연 / 교통 흐름 영향 정도
- 사고 이후에만 알 수 있는 변수는 제외하고, 사고 발생 조건 변수 중심으로 학습 진행 -> 예측
- 클래스 불균형이 큰 데이터이므로 **Macro F1**을 주요 기준으로 모델 선정

데이터셋 소개

7.73M

원본 사고 데이터 행 수

100K

층화 샘플링 데이터

34

최종 선택 변수 수

4

Severity 클래스

Dataset	US Accidents (2016–2023)
Source	Kaggle
Target	Severity
Task	Multiclass Classification
Split	Train 70% / Validation 15% / Test 15%

- 원본 CSV는 용량이 커서 층화 샘플링 적용
- Severity 비율 유지를 위해 **stratify** 옵션으로 데이터 분할

실험 요약: sampled_shape=(100000,34), processed_shape=(100000,37), train=69,997, validation=15,003, test=15,000

사용 변수와 정보 누수 방지

시간

Month
DayOfWeek
Hour

위치

Start_Lat / Lng
State · City
County · Timezone

기상

Temperature
Humidity
Visibility
Weather_Group



도로환경

Traffic Signal
Junction
Crossing
Stop 등

제외 변수: End_Time, Distance(mi), End_Lat, End_Lng, Description


사고가 끝난 후에 알 수 있거나 결과에 직접 연결될 수 있는 변수는 실제 예측 상황을 고려해 제외했다.

클래스 불균형 : Accuracy만으로는 부족





Severity 2가 다수를 차지하므로 Macro F1과 Balanced Accuracy를 함께 사용했다.

전처리 파이프라인



EDA 1: 시간·월별 사고 패턴



시간대와 월별 패턴을 통해 Month, DayOfWeek, Hour 파생 변수의 활용 가능성을 확인했다.

EDA 2: 기상 조건과 사고 Severity

그림 6. 날씨 그룹별 사고 발생 건수







그림 10. 사고 심각도별 평균 가시거리



날씨 그룹과 가시거리 변수는 사고 발생 환경을 설명하는 핵심 입력으로 활용했다.


EDA 3: 도로 환경 변수의 차이



신호등, 교차로, 횡단보도 등 주변 도로 시설 정보는 사고 심각도와 관련된 설명 변수로 사용했다.

EDA 3: 도로 환경 변수의 차이


그림 12. 도로환경 변수별 해당 비율



신호등, 교차로, 횡단보도 등 주변 도로 시설 정보는 사고 심각도와 관련된 설명 변수로 사용했다.

EDA 4: 위치 기반 사고 분포

그림 13. 미국 교통사고 위치 분포 (Severity 1~4)



- 위도·경도를 활용해 미국 내 사고의 공간적 분포 확인
- 특정 지역 위주로 심각도가 몰려있음
-> 위치 변수가 **Severity**에 영향이 있음
- 도시 밀집 지역 위주로 심각도가 쏠려 있음

평가 지표

평가 지표

Accuracy
Balanced Accuracy
Macro F1
Weighted F1

최종 평가 지표

주요 평가지표 :
Macro F1-score

보조 평가지표 :
Balanced_accruacy
weighted_f1
accuracy

- Severity 2 -> 클래스 불균형
- Accuracy만 사용하면 문제 발생
- Macro_f1 : 클래스별 성능을 균등하게 반영

Macro_f1에 맞춘 모델링 전략

사용 모델 + **Balanced**

Dummy

Logistic Regression

Decision Tree


Random Forest

HistGradientBoosting

=> **RF Balanced**

- 초기에는 5개의 모델 사용
- 클래스 불균형을 해소하기 위해 Class Weight = Balanced 추가 -> 1개의 모델 선정
- 클래스 불균형을 해소하기 위해 3개의 모델 추가

그림 19. 모델별 Validation Macro F1 비교



Random Forest 하이퍼파라미터 비교

그림 14. Random Forest max_depth 변화에 따른 성능 비교





그림 15. Random Forest min_samples_leaf 변화에 따른 성능 비교



최종 모델 후보는 클래스 불균형을 고려한 Random Forest 계열에서 도출되었다.

Random Forest 클래스 불균형 추가 처리 실험

총 4가지의 실험 진행

- UnderSampling

: 다수 클래스 샘플을 줄임

- Manual class_weight

: 소수 클래스에 직접 가중치 부여

- RandomOverSampler

: 소수 클래스 샘플을 복제

- SMOTE

: 소수 클래스 가상 샘플 생성


undersampling cap : 각 클래스별 학습 샘플 수를 최대 3000/5000/10000개로 제한

모델	가중치
ManualWeight 1	{1: 2, 2: 1, 3: 2, 4: 4}
ManualWeight 2	{1: 3, 2: 1, 3: 2, 4: 5}
ManualWeight 3	{1: 4, 2: 1, 3: 3, 4: 6}

최종 모델 후보는 클래스 불균형을 고려한 Random Forest 계열에서 도출되었다.

Random Forest 클래스 불균형 추가 처리 실험 : macro_f1 평가지표

model	macro_f1
RF RandomOverSampler	0.408993
RF SMOTE	0.401270
RF UnderSampling cap=5000	0.380355
RF UnderSampling cap=3000	0.375037
RF ManualWeight 3	0.358648
RF ManualWeight 2	0.344153
RF UnderSampling cap=10000	0.337659
RF ManualWeight 1	0.336881



최종 모델 후보는 클래스 불균형을 고려한 Random Forest 계열에서 도출되었다.

최적 모델 선정을 위한 모델 후보 추가

추가 된 사용 모델

XGBoost Weighted

LightGBM Balanced


Dense Neural Network

(64개 뉴런을 가진 은닉층 하나 + Dropout 0.3을 적용한 간단한 신경망)

model	macro_f1
XGBoost Weighted	0.348077
LightGBM Balanced	0.360116
Simple Dense Neural Network	0.296571

최종 모델 후보는 클래스 불균형을 고려한 Random Forest 계열에서 도출되었다.

모델 비교 결과: Macro F1 Top 10



최종 선정 모델

**RF Balanced
min_samples_leaf=5**

Validation Macro F1을 기준으로 여러 후보 모델을 공정하게 비교했다.


최종 모델 해석: 주요 변수 중요도

Rank	Feature	Importance
1	Start_Lng	0.0759
2	Start_Lat	0.0742
3	Wind_Chill(F)	0.0710
4	Month	0.0624
5	Pressure(in)	0.0603
6	Temperature(F)	0.0572
7	Hour	0.0561
8	Humidity(%)	0.0486

- 위치 변수(Start_Lat/Lng)가 높은 중요도를 보임
- 월, 시간, 기상 변수도 상위권에 포함

최종 모델 평가: Test set 결과

그림 18. Confusion Matrix - RF Balanced min_samples_leaf=5



Metric	Value
Accuracy	0.7415
Balanced Accuracy	0.4417
Macro F1	0.4185
Weighted F1	0.7546

- Severity 2 예측 성능은 상대적으로 높음
- Severity 1·4는 클래스 개수가 적어 예측 성능이 낮음
- 불균형 데이터의 한계가 **Confusion Matrix**에서 확인됨

Streamlit 웹앱 구현



- Folium 지도에서 사고 위치 클릭 → 위도·경도 자동 입력
- 가장 가까운 기존 사고 지점을 기준으로 **State, City, County, Timezone** 자동 설정
- 노트북에서 저장한 전처리 기준과 최종 모델을 **joblib artifact**로 불러와 동일하게 예측
- 예측 **Severity**와 클래스별 확률을 웹 화면에 출력

US Accidents Severity 예측

localhost:8501

채팅

Deploy




교통사고 Severity 예측 웹앱

지도에서 사고 위치를 선택하고, 기상 조건과 도로 환경 정보를 입력하면 학습된 모델이 사고 심각도 등급을 예측합니다.

현재 사용 모델: RF Balanced min_samples_leaf=5

1) 사고 위치 선택

미국 지도에서 사고 위치를 클릭하면 위도·경도와 가장 가까운 사고 데이터 기준의 주, 도시, 카운티, 시간대가 자동 입력됩니다.



Leaflet | © OpenStreetMap contributors

선택 좌표와 가장 가까운 기존 사고 데이터를 기준으로 위치 정보를 설정했습니다. 최근접 거리: 0.59 km

2) 사고 기본 정보

US Accidents Severity 예측

localhost:8501

Deploy

선택 좌표와 가장 가까운 기존 사고 데이터를 기준으로 위치 정보를 설정했습니다. 최근접 거리: 0.59 km

2) 사고 기본 정보

사고 날짜	주(State)	카운티(County)	위도(Start_Lat)
2023/07/15	NY	New York	40.733730 - +
사고 시간	도시(City)	시간대(Timezone)	경도(Start_Lng)
18 - +	New York	US/Eastern ▾	-74.012512 - +

3) 기상 정보

날씨	체감온도(F)	기압(in)	풍속(mph)
Rain ▾	50.00 - +	5.00 - +	5.00 - +
기온(F)	습도(%)	가시거리(mi)	풍향
54.00 - +	63.00 - +	9.50 - +	CALM ▾
☐ 강수량 정보 없음		강수량(in)	
		0.00 - +	

4) 주야간 및 도로 환경 정보

주야간(Sunrise/Sunset)	정지표지판 여부	편의시설 인접 여부	막다른 길 여부
Day ▾	No ▾	No ▾	No ▾
신호등 여부	역/정류장 여부	과속방지턱 여부	Turning Loop 여부
Yes ▾	No ▾	No ▾	No ▾
교차로 여부	철도 인접 여부	교통정원화시설 여부	Civil Twilight
Yes ▾	No ▾	No ▾	Day ▾

US Accidents Severity 예측

localhost:8501

채팅

Deploy

예측하기

결과: 예측 Severity = 2

Severity 2: 일반적인 수준의 사고 영향

Severity별 예측 확률

Severity	Probability
1	0.0434
2	0.4582
3	0.2051
4	0.2933

입력값 확인

```
{
  "Start_Time": "2023-07-15 18:00:00"
  "Start_Lat": 40.73373036205216
  "Start_Lng": -74.01251167686512
  "State": "NY"
  "County": "New York"
  "City": "New York"
  "Timezone": "US/Eastern"
  "Temperature(F)": 54
  "Wind_Chill(F)": 50
  "Humidity(%)": 63
  "Pressure(in)": 5
  "Visibility(mi)": 9.5
  "Wind_Direction": "CALM"
  "Wind_Speed(mph)": 5
}
```

최종 결론 및 개선 방향

US Accidents 데이터를 활용해 교통사고 **Severity 4분류 모델**을 개발하고,
평가지표 **macro_f1**을 기준으로

최종 모델을 **RF Balanced min_samples_leaf=5** 으로 선정,

-> **Streamlit 웹앱**으로 연결하여 모델 직접 사용

성과

- 데이터 불균형을 해결하기 위해 여러 모델 사용 시도
- **Macro F1** 기준 모델 비교
- 웹앱 기반 예측 기능 구현

한계

- **Severity 2** 중심 불균형
- **Severity 1~4** 예측 성능 부족
- 입력 변수 :
교통량·속도·차종 변수 부재

개선

- 외부 교통·도로 데이터 결합
- **2분류/3분류** 문제 재정의

US Accidents Severity 예측 프로젝트

감사합니다